

АНАЛИЗ БОЛЬШИХ ДАННЫХ

Лекция 1

Обработка естественного языка (NLP) и большие языковые модели (LLM): обзор

Занятие 10.09.2026 · источники: конспект «обработка естественного языка.txt», слайд 1, рисунки «NLP-конвейер» и «Векторизация слов»

Как читать. Основной текст — из твоих материалов (конспект + скрины слайдов); в скобках (слайд N) указано, откуда взято. **[дополнение]** — то, чего в материалах нет, добавлено мной для понимания. **[неясность]** — место, которое нельзя восстановить однозначно; подробности в разделе «Спорные и неоднозначные места».

Ключевые определения и теоремы

NLP (Natural Language Processing, обработка естественного языка) — направление, в котором компьютер анализирует, понимает и порождает тексты на естественном (человеческом) языке.

LLM (Large Language Model, большая языковая модель) — модель, способная обучаться и генерировать текст на естественном языке. LLM — частный случай NLP.

«**Большая**» означает два измерения: большой объём обучающих данных (порядка 10^{15} байт) и большое число параметров (порядка 10^{11} весов).

Формальный язык $L = L(G)$ — множество всех цепочек, которые порождает грамматика G .

КС-грамматика (контекстно-свободная) G : алфавит терминалов $A = \{a_1, \dots, a_k\}$, множество нетерминалов $V = \{v_1, \dots, v_e\}$, начальный символ $S \in V$ и правила вида $v \rightarrow w$, где $v \in V$, а w — цепочка из терминалов и нетерминалов.

Однозначный / двусмысленный язык. Если у каждой фразы ровно один разбор, языку можно приписать точную семантику (как языку программирования). Естественный язык двусмыслен, поэтому для него применяют машинное обучение и нейросети.

Словарь и корпус. $V = \{w_1, \dots, w_K\}$ — словарь (токены), $D = \{d_1, \dots, d_N\}$ — корпус документов.

Евклидово расстояние между векторами слов $A = (a_1, \dots, a_m)$ и $B = (b_1, \dots, b_m)$:

$$\text{dist}(A, B) = \sqrt{\vec{AB} \cdot \vec{AB}} = \sqrt{\sum_{i=1}^m (b_i - a_i)^2} = |\vec{AB}|.$$

Отношение is-a («является») задаёт иерархию понятий: собака is-a животное, животное is-a существо.

1. Вводные понятия

1.1. Методы обучения, упомянутые в начале

В конспекте в начале лекции записаны две строки:

- **Метод обратного распространения ошибки** — в конспекте строка обрывается на «кр...» **[неясность]**. **[дополнение]** Это основной способ обучения нейросетей: считаем ошибку на выходе сети и «прогоняем» её назад по слоям, чтобы понять, как изменить каждый вес, чтобы ошибка уменьшилась.
- **Обучение с подкреплением для больших моделей.** **[дополнение]** Модель получает «награду» за хорошие ответы и «штраф» за плохие и подстраивается так, чтобы награда росла. Для LLM так дообучают модель на оценках людей (RLHF).

1.2. Три вида семантики

Семантика — это смысл высказывания. В конспекте выделены три вида:

Вид	Аналог в естественном языке	Аналог в программировании / данных
Императивная	побудительные предложения («сделай...»)	как в языках программирования: процедуры, функции, типы данных
Декларативная	утверждения о мире	предикаты, операции, абстрактные типы
Интеррогативная	вопросы	факты и данные, задачи, запросы и ответы

[дополнение] Столбец «аналог в естественном языке» для декларативной и интеррогативной семантики я достроил по смыслу названий: «декларативный» — утверждающий, «интеррогативный» — вопросительный.

2. Большие языковые модели (LLM)

(конспект, слайд 1)

LLM — large language model, большая языковая модель. Это модель, которая может обучаться и генерировать текст на естественном языке. LLM — частный случай NLP.

Слово «большая» относится к двум вещам:


- **объём данных:** порядка 10^{15} байт;
- **число параметров:** $100\,000\,000\,000 = 10^{11}$ весов.

[дополнение] Для масштаба: 10^{15} байт = 1 петабайт, примерно миллион жёстких дисков по 1 ГБ. Вес — это число внутри нейросети, которое подбирается при обучении. 10^{11} — это сто миллиардов таких чисел.

3. Язык как множество, порождаемое грамматикой

(слайд 1, конспект)

Язык рассматривается как $L = L(G)$ — множество фраз, порождаемых грамматикой G .
Дальше развилка:



Главная мысль. Если у каждой фразы языка один-единственный смысл (так устроены языки программирования), смысл можно задать точными правилами. Естественный язык *двусмыслен*: одна и та же фраза может значить разное, поэтому точных правил не хватает и приходится *обучать* модель на данных. Так и появляются машинное обучение, нейросети и LLM. Конкретный пример двусмысленности разобран в лекции 2 («I took her flowers»).

3.1. Обозначения для КС-грамматики

(конспект)

- $A = \{a_1, \dots, a_k\}$ — алфавит, то есть терминальные символы (конкретные слова);
- $V = \{v_1, \dots, v_e\}$ — нетерминальные символы (категории вроде «предложение», «именная группа»);
- $S \in V$ — начальный символ (в конспекте распознано как «S E v»; имеется в виду $S \in V$);
- правила вида $v \rightarrow w$: нетерминал v заменяется цепочкой w ;
- G — КС-грамматика (контекстно-свободная): слева в каждом правиле стоит *один* нетерминал.

В конспекте есть ещё запись « $A \rightarrow w$ » **[неясность]**: та же буква A уже занята алфавитом. Скорее всего, это общий вид правила, где A — какой-то нетерминал.

4. Задачи NLP и NLP-конвейер

4.1. Что решает NLP

(конспект; тот же список повторяется на слайде 6 лекции 3)


- анализ текста;
- распознавание и синтез речи;
- выделение сущностей и фактов;

- перевод текста на другой язык;
- разработка диалоговых систем.

4.2. Конвейер обработки текста

(рисунок «NLP-конвейер»)

Текст проходит цепочку этапов. Каждый этап обменивается данными с общими **таблицами** (словари, справочники и т. п.):



Что делает каждый этап. Сами этапы взяты с рисунка, пояснения и примеры — **[дополнение]**, кроме отмеченного:

- 1) **Токенизация и сегментация.** Текст режется на предложения и *токены* (слова, знаки). Из токенов составляется **словарь** $V = \{w_1, \dots, w_K\}$, а набор текстов образует **корпус документов** $D = \{d_1, \dots, d_N\}$ (конспект).
- 2) **Морфологический анализ и фильтрация стоп-слов.** Сюда относятся стемминг и лемматизация: разные формы слова сводятся к одной основе. Пример из конспекта: *helping, helpful* → *help*. Стоп-слова (*и, в, на, the, а*) почти не несут смысла и часто выбрасываются.
- 3) **Разрешение кореференции.** Нужно понять, что разные выражения обозначают один объект: «*Маша* взяла книгу. *Она* её прочитала.» Здесь «она» = Маша, «её» = книга.
- 4) **Парсинг зависимостей.** Строится дерево связей между словами: кто подлежащее, что от чего зависит. Деревья разбора подробно разобраны в лекции 2.
- 5) **Векторизация текста.** Слова и тексты превращаются в векторы чисел, с которыми умеет работать компьютер (см. ниже и лекцию 3).
- 6) **Генерация текста.** По векторам строится ответный текст. Именно это умеют делать LLM.


[дополнение] стемминг и лемматизация — в чём разница

Стемминг грубо обрезает окончания и суффиксы: *helping*→*help*, *helpful*→*help*. **Лемматизация** приводит слово к словарной форме: *helping*→*help*, но *helpful* остаётся *helpful*, потому что это отдельное слово-прилагательное. Пример из конспекта поэтому точнее описывает стемминг.

5. Векторизация слов

(рисунок «Векторизация слов», конспект)

Каждое слово превращают в точку (вектор) в многомерном пространстве. Слова, близкие по смыслу, оказываются рядом и образуют «облачка» (кластеры):



Насколько слова похожи, измеряют **расстоянием** между их векторами. В конспекте — евклидово расстояние:

$$\text{dist}(A, B) = \sqrt{\vec{AB} \cdot \vec{AB}} = \sqrt{\sum_{i=1}^m (b_i - a_i)^2} = |\vec{AB}|,$$

где $A = (a_1, \dots, a_m)$ и $B = (b_1, \dots, b_m)$ — векторы двух слов. Это обычная длина отрезка AB , только в m -мерном пространстве. На рисунке у суммы верхний предел n , в лекции 3 — m ; это одно и то же: размерность векторов.

Пример из конспекта:

$$\text{dist}(\text{собака}, \text{кошка}) = 2, \quad \text{dist}(\text{кошка}, \text{трава}) = 5, \quad \text{dist}(\text{трава}, \text{дерево}) = 3.$$

«Собака» и «кошка» — оба животные, поэтому они близко. «Кошка» и «трава» относятся к разным ветвям иерархии и лежат далеко друг от друга.

Задача [дополнение]: посчитать расстояние по формуле


Пусть слова заданы векторами $A = (1, 2, 0)$ и $B = (3, 1, 2)$. Найти $\text{dist}(A, B)$.

Решение. Вычитаем по координатам: $b - a = (3 - 1, 1 - 2, 2 - 0) = (2, -1, 2)$. Возводим в квадрат и складываем: $4 + 1 + 4 = 9$. Извлекаем корень: $\text{dist}(A, B) = \sqrt{9} = 3$.

Смысл: чем меньше число, тем ближе слова по смыслу (если векторы построены хорошо).

6. Иерархия понятий (отношение is-a)

(конспект; та же схема на слайде лекции 3)



Каждая связь читается снизу вверх как «является»: собака *is-a* животное, животное *is-a* существо. Такая иерархия хорошо согласуется с расстояниями выше: «братья» по одной ветке (собака-кошка, трава-дерево) ближе друг к другу, чем слова из разных веток (кошка-трава).

7. Спорные и неоднозначные места

Место	Что в материалах	Моя гипотеза
«Метод обратного распространения ошибок — кр»	Строка конспекта оборвана.	Возможно, «кратко» или начало пояснения, которое не успели записать. Восстановить нельзя.
Заголовок «2 лекция» внутри файла первой лекции	Файл лежит в папке «первая лекция» и датирован 10.09, но строки 11 подписан «2 лекция».	Скорее всего, это вторая пара того же дня. Поэтому весь файл отнесён к лекции 1.
«S E v»	Так написано в конспекте.	Это $S \in V$: начальный символ принадлежит множеству нетерминалов.
« $A \rightarrow w$ »	В той же записи A — алфавит $\{a_1, \dots, a_k\}$.	Общий вид правила «нетерминал $\rightarrow$ цепочка»; буква A использована повторно.
Размер словаря	В конспекте $v = \{w_1, \dots, w_m\}$, $D = \{d_1, \dots, d_n\}$; на слайдах лекций 2-3 $V = \{w_1, \dots, w_K\}$, $D = \{d_1, \dots, d_N\}$.	Обозначения разные, смысл один. Здесь взяты слайдовые K и N , чтобы m осталось размерностью векторов.
Верхний предел суммы в dist	На рисунке лекции 1 — n , на слайде лекции 3 — m .	Это размерность пространства; правильнее m , так как векторы лежат в $\mathbb{R}^m$.
Числа расстояний	Конспект: 2 и 5; слайд 6 лекции 3: 2,5 и 15,8 для тех же пар.	Числа иллюстративные: важно не значение, а то, что собака-кошка намного ближе, чем кошка-трава.
helpful $\rightarrow$ help	Подано как стемминг/лемматизация вместе.	Для лемматизации это неточно (см. блок дополнение в разд. 4).

8. Вопросы для самопроверки

1. Что такое LLM и как она связана с NLP?
2. В каких двух смыслах модель «большая»? Какие порядки величин назывались?
3. Чем отличаются императивная, декларативная и интеррогативная семантика?
4. Почему для однозначного языка можно задать точную семантику, а для естественного приходится использовать машинное обучение?
5. Из каких частей состоит КС-грамматика? Что такое S ?
6. Назови по порядку этапы NLP-конвейера. Зачем нужны «таблицы»?
7. Что такое кореференция? Приведи свой пример.
8. Найди $\text{dist}(A, B)$ для $A = (0, 0, 0)$, $B = (1, 2, 2)$.
9. Почему расстояние «собака-кошка» меньше, чем «кошка-трава»? Объясни через иерархию is-a.

Краткие ответы. 1) Модель, которая обучается и генерирует текст; частный случай NLP. 2) Объём данных ($\sim 10^{15}$ байт) и число параметров ($\sim 10^{11}$ весов). 3) Побуждение/команды; утверждения/предикаты; вопросы/запросы. 4) У однозначного языка каждая фраза разбирается одним способом, а естественный язык двусмыслен. 5) A — терминалы, V — нетерминалы, $S \in V$ — начальный символ, правила $v \rightarrow w$. 6) Токенизация $\rightarrow$ морфология и стоп-слова $\rightarrow$ кореференция $\rightarrow$ парсинг зависимостей $\rightarrow$ векторизация $\rightarrow$ генерация; таблицы — общие словари и справочники этапов. 7) Несколько выражений обозначают один объект («Пётр... он...»). 8) $\sqrt{1+4+4} = 3$. 9) Собака и кошка — дети одного узла «животное», а кошка и трава расходятся только на уровне «существо».