

АНАЛИЗ БОЛЬШИХ ДАННЫХ

Лекция 3

Векторизация текста: one-hot, мешок слов, TF-IDF, вложения слов

Занятие 24.09.2026 · источники: слайды 1-6 (14 скриншотов)

Как читать. Основной текст — из твоих материалов (конспект + скрины слайдов); в скобках (слайд N) указано, откуда взято. **[дополнение]** — то, чего в материалах нет, добавлено мной для понимания. **[неясность]** — место, которое нельзя восстановить однозначно; подробности в разделе «Спорные и неоднозначные места».

Ключевые определения и теоремы

Словарь токенов и корпус документов $V = \{w_1, \dots, w_K\}$, $D = \{d_1, \dots, d_N\}$.

Векторизация — сопоставление каждому токenu вектора чисел:

$$w_i \mapsto x_i = [x_i^1, \dots, x_i^m] \in \mathbb{R}^m.$$

Верхний индекс здесь — номер координаты, а не степень.

One-hot-кодирование (слайд 2; название — **[дополнение]**) — слову w_i сопоставляется вектор длины K , где на i -м месте стоит 1, а на остальных 0.

Мешок слов (bag of words) — документ кодируется вектором длины K : на i -м месте стоит число вхождений слова w_i в документ. Порядок слов теряется.

TF (частота термина): $\text{tf}(w_i, d_j) = \frac{n(w_i, d_j)}{n(d_j)}$, $0 \leq \text{TF} \leq 1$.

IDF (обратная документная частота): $\text{idf}(w_i, D) = \log \frac{N}{n_i}$, где N — число документов, n_i — число документов, содержащих w_i .

TF-IDF: $\text{tf-idf}(w_i, d_j, D) = \text{tf}(w_i, d_j) \cdot \text{idf}(w_i, D)$. Большой вес получают слова, которые в данном документе встречаются чаще, чем в остальной части корпуса.

Вложения слов (word embeddings) — плотные векторы, в которых близкие по смыслу слова лежат рядом. Близость измеряется расстоянием $\text{dist}(A, B) = \sqrt{\sum_{i=1}^m (b_i - a_i)^2}$.

Онтология и отношение is-a — иерархия понятий («собака является животным»).

1. Постановка задачи

(слайд 1)

И в классическом NLP, и в LLM компьютер работает не со словами, а с числами. Поэтому каждый токен из словаря надо превратить в вектор:

$V = \{w_1, \dots, w_K\}$ — словарь токенов, $D = \{d_1, \dots, d_N\}$ — корпус документов,

$$w_i \mapsto x_i = [x_i^1, \dots, x_i^m] \in \mathbb{R}^m.$$

Вся лекция — о том, как выбрать такие векторы. Рассмотрены три способа (one-hot, мешок слов, TF-IDF) и идея вложений.

2. Сквозной пример

(слайд 1)

$$S_1: \text{«Пёс сел на пенё.»} \quad S_2: \text{«Кот сел на ель.»}$$

$$V = \{\text{Пёс, Кот, ель, на, сел, пенё}\} \quad (K = 6), \quad D = [d_1, d_2] \quad (N = 2),$$

$$d_1 = [\text{Пёс, сел, на, пенё}], \quad d_2 = [\text{Кот, сел, на, ель}].$$

Порядок слов в словаре (Пёс, Кот, ель, на, сел, пенё) дальше задаёт порядок координат во всех векторах.

3. One-hot-кодирование

(слайд 2)

Каждому слову словаря даётся «своя» координата:

$$\text{Пёс} \mapsto [1, 0, 0, 0, 0, 0], \quad \text{Кот} \mapsto [0, 1, 0, 0, 0, 0], \quad \dots, \quad \text{пенё} \mapsto [0, 0, 0, 0, 0, 1].$$

На слайде документ записан как таблица 6×6 : по одной строке на каждое слово словаря. Если слово есть в документе, в строке стоит его one-hot-вектор, если нет — нули:

$$d_1 = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{matrix} \text{Пёс} \\ \text{Кот} \\ \text{ель} \\ \text{на} \\ \text{сел} \\ \text{пенё} \end{matrix} \quad d_2 = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} \begin{matrix} \text{Пёс} \\ \text{Кот} \\ \text{ель} \\ \text{на} \\ \text{сел} \\ \text{пенё} \end{matrix}$$

[дополнение] минусы one-hot

- Длина вектора равна размеру словаря K , а в реальных словарях это десятки и сотни тысяч слов. Почти все координаты — нули.
- Любые два разных слова находятся на одинаковом расстоянии: $\text{dist}(\text{Пёс, Кот}) = \text{dist}(\text{Пёс, пенё}) = \sqrt{1^2 + 1^2} = \sqrt{2}$. Сходство по смыслу one-hot не отражает. Эту проблему решают вложения слов (разд. 6).

4. Мешок слов (bag of words)

(слайд 3)

Упрощаем: вместо таблицы храним *один* вектор на документ. На i -м месте стоит, сколько раз слово w_i встретилось в документе:

$$D = \begin{bmatrix} 1 & 0 & 0 & 1 & 1 & 1 \\ 0 & 1 & 1 & 1 & 1 & 0 \end{bmatrix} \begin{matrix} d_1 \\ d_2 \end{matrix} \quad (\text{столбцы: Пёс, Кот, ель, на, сел, пенё}).$$

Заметь: строка мешка слов — это сумма строк one-hot-таблицы документа. Например, для d_1 : $[1, 0, 0, 0, 0, 0] + [0, 0, 0, 1, 0, 0] + [0, 0, 0, 0, 1, 0] + [0, 0, 0, 0, 0, 1] = [1, 0, 0, 1, 1, 1]$.

[дополнение] Название «мешок» объясняется так: слова как будто высыпали в мешок, и порядок потерялся. «Пёс сел на пенё» и «пенё сел на пса» (после лемматизации) дадут одинаковый вектор. В нашем примере все числа равны 1, потому что каждое слово встречается в предложении один раз; в общем случае это счётчики (2, 3, ...).

5. Частотный анализ: TF-IDF

(слайды 3–4)

5.1. Формулы

TF — насколько слово частое *внутри документа*:

$$\text{tf}(w_i, d_j) = \frac{n(w_i, d_j)}{n(d_j)}, \quad 0 \leq \text{TF} \leq 1,$$

где $n(w_i, d_j)$ — число вхождений w_i в d_j , а $n(d_j)$ — общее число слов в $d_j \in D$.

IDF — насколько слово *редкое по корпусу*:

$$\text{idf}(w_i, D) = \log \frac{N}{n_i}.$$

Здесь N — число документов в корпусе. Буква n_i на слайде не расшифрована; это число документов, в которых встречается w_i **[дополнение]** (стандартное определение, и с ним сходятся числа в таблице ниже).

TF-IDF — их произведение:

$$\text{tf-idf}(w_i, d_j, D) = \text{tf}(w_i, d_j) \cdot \text{idf}(w_i, D).$$

Как это понимать (слайд 4). Если w_i встречается в D часто, значение IDF *снижается*, в противном случае IDF *возрастает*. Большой вес TF-IDF получают слова, которые в данном документе встречаются чаще, чем в остальной части D .

Иначе говоря, слова, которые есть везде («на», «сел», «и»), ничего не говорят о конкретном документе, и их вес обнуляется. Слова, характерные именно для этого документа, получают большой вес.

Задача 1. Посчитать TF-IDF для сквозного примера

Шаг 1. Длины документов. В каждом по 4 слова: $n(d_1) = n(d_2) = 4$.

Шаг 2. TF. Каждое слово встречается в своём документе один раз, поэтому $\text{tf} = \frac{1}{4}$, если слово есть, и 0, если его нет.

Шаг 3. IDF ($N = 2$):

- Пёс, Кот, ель, пенё встречаются в одном документе: $\text{idf} = \log \frac{2}{1} = \log 2$;
- на, сел встречаются в обоих: $\text{idf} = \log \frac{2}{2} = \log 1 = 0$.

Шаг 4. TF-IDF. Для «Пёс» в d_1 : $\frac{1}{4} \cdot \ln 2 = \frac{1}{4} \cdot 0,693 \approx 0,17$. Для «на» в любом документе: $\frac{1}{4} \cdot 0 = 0$.


Собака и кошка — оба животные, поэтому расстояние маленькое. Трава из другой «ветки», поэтому расстояние большое.

[дополнение] Такие векторы не задают вручную, а *обучают* на больших корпусах (например, методом word2vec). Слова, которые встречаются в похожих контекстах, получают похожие векторы. Размерность m обычно порядка сотен, а не K — десятков тысяч, как у one-hot.

7. Логика и онтология

(слайд 5, нижняя часть)

Есть и «ручной» способ описать смысл слов — **онтология**, то есть иерархия на основе отношения **is-a**:



Онтология и вложения согласованы: слова из одной ветки (собака, кошка) близки и в пространстве векторов. Слова из разных веток (кошка, трава) далеки.

8. Где всё это применяется

(слайд 6; тот же список — в лекции 1)

NLP и LLM используют векторизацию для анализа текстов; распознавания и синтеза речи; выделения сущностей и фактов; перевода текста на другой язык; разработки диалоговых систем.

9. Спорные и неоднозначные места

Место	Что в материалах	Моя гипотеза
«Ком», «Пес», «Кор»	Так читаются рукописные слова на слайдах 1–5.	«Кот», «Пёс», «Кот» — по смыслу примера и рифме «Пёс/Кот».
Порядок d_2, d_1	На слайде сначала выписан d_2 , потом d_1 ; подпись d_1 исправлена вверх.	Это просто порядок записи на доске; d_1 — про пса, d_2 — про кота (сходится с one-hot и мешком слов).
Форма one-hot для документа	Документ — таблица 6×6 с нулевыми строками для отсутствующих слов.	Обычно документ записывают как последовательность one-hot-векторов его слов (4×6). Информация та же, слайдовая форма удобна для перехода к мешку слов.
n_i в IDF	Не определено на слайде.	Число документов, содержащих w_i : только так получаются $\log \frac{2}{1}$ и $\log \frac{2}{2}$ в таблице.
Основание логарифма	Не указано.	Натуральный: $\frac{1}{4} \ln 2 \approx 0,17$ (см. задачу).
Число «2» сверху скрина с онтологией	Обрезанная строка над «логика и онтология».	Восстановить нельзя [неясность] ; возможно, номер пункта или конец формулы.
Числа расстояний	Здесь 2,5 и 15,8; в конспекте лекции 1 — 2 и 5.	Иллюстративные значения; важно соотношение «мало/много».
Нумерация слайдов	На двух разных скринах стоит «Слайд 1» и «Слайд 2»; заголовок слайда 5 перекрыт текстом.	Слайды дополнялись по ходу лекции; на содержание не влияет.

10. Вопросы для самопроверки

1. Что обозначает запись $w_i \mapsto x_i = [x_i^1, \dots, x_i^m] \in \mathbb{R}^m$? Что такое m и что означает верхний индекс?
2. Запиши one-hot-векторы слов «ель» и «сел» для словаря из примера.
3. Как из one-hot-таблицы документа получить его мешок слов?
4. Что теряет мешок слов? Приведи пример двух разных предложений с одинаковым мешком.
5. Почему $0 \leq \text{TF} \leq 1$?
6. Почему IDF слова «на» равен нулю? Что это значит по смыслу?
7. Добавь в корпус $d_3 = \text{«Пёс сел на ель»}$. Найди новые IDF слов «на», «ель», «пень» (логарифм натуральный).
8. Чем вложения слов лучше one-hot? Почему в one-hot все слова «одинаково далеки»?
9. Как связаны онтология (is-a) и расстояния между векторами слов?

Краткие ответы. 1) Каждому токеноу сопоставлен вектор из m чисел; m — размерность, x_i^j — j -я координата вектора слова w_i . 2) ель = $[0, 0, 1, 0, 0, 0]$, сел = $[0, 0, 0, 0, 1, 0]$. 3) Сложить все строки

таблицы. 4) Порядок слов: «пёс видит кота» и «кот видит пса» (после лемматизации). 5) Число вхождений слова не больше числа всех слов документа. 6) Оно есть во всех документах: $\log \frac{2}{2} = 0$. Слово не помогает различать документы. 7) $N = 3$: «на» — во всех трёх, $\ln \frac{3}{3} = 0$; «ель» — в двух, $\ln \frac{3}{2} \approx 0,405$; «пень» — в одном, $\ln 3 \approx 1,099$. 8) Вложения короче и отражают смысл. В one-hot у разных слов единицы стоят на разных местах, поэтому расстояние между любыми двумя словами равно $\sqrt{2}$. 9) Слова из одной ветки иерархии оказываются ближе в пространстве векторов.