

АНАЛИЗ БОЛЬШИХ ДАННЫХ

Лекция 2

Формальные грамматики, деревья разбора и двусмысленность

Занятие 17.09.2026 · источники: слайды 2-5 (9 скриншотов)

Как читать. Основной текст — из твоих материалов (конспект + скрины слайдов); в скобках (слайд N) указано, откуда взято. **[дополнение]** — то, чего в материалах нет, добавлено мной для понимания. **[неясность]** — место, которое нельзя восстановить однозначно; подробности в разделе «Спорные и неоднозначные места».

Ключевые определения и теоремы

Грамматика (КС) — набор правил вида $X \rightarrow \alpha$: символ X можно заменить цепочкой α . Запись $X \rightarrow \alpha \mid \beta$ означает « $X \rightarrow \alpha$ или $X \rightarrow \beta$ ».

Нетерминалы — категории (S, NP, VP, N, PRO, V, DET, MOD). **Терминалы** — конкретные слова (*I, took, her, flowers*).

Вывод [дополнение] — последовательность замен от S до цепочки из одних терминалов, например $S \Rightarrow NP VP \Rightarrow \dots \Rightarrow I took her flowers$.

Дерево разбора — дерево, в корне которого S , во внутренних узлах нетерминалы, в листьях слова. Каждый узел вместе с детьми — одно применённое правило.

Двусмысленность (неоднозначность) — у одной и той же фразы есть **два и более разных дерева разбора**. Разные деревья означают разные смыслы.

Токен, словарь, документ, корпус — базовые объекты векторизации: словарь $V = \{w_1, \dots, w_K\}$, корпус $D = \{d_1, \dots, d_N\}$.

1. Пример: грамматика подмножества английского языка

(слайд 2)

Чтобы увидеть, как работает грамматика из лекции 1, возьмём маленький кусочек английского. Символы (нетерминалы):

Символ	Английское название	Смысл
S	Sentence	предложение
NP	Noun Phrase	именная группа
VP	Verb Phrase	глагольная группа
N	Noun	существительное
PRO	Pronoun	местоимение
V	Verb	глагол

1.1. Правила

(слайд 2)

$$\begin{aligned}
 S &\rightarrow NP VP \\
 NP &\rightarrow N \mid PRO \mid PRO N \\
 VP &\rightarrow V NP \mid V NP NP \\
 N &\rightarrow planes \mid flowers \mid \dots \\
 PRO &\rightarrow they \mid I \mid her \mid \dots \\
 V &\rightarrow was \mid took \mid \dots
 \end{aligned}$$

Как читать: «предложение — это именная группа, за которой идёт глагольная»; «именная группа — это либо существительное, либо местоимение, либо местоимение + существительное»; «глагольная группа — это глагол с одним или с двумя дополнениями». Последние три строки — словарь: какие слова к какой категории относятся.

2. Задача 1: «I took her flowers»

(слайды 2-3)

Задача 1. Построить все деревья разбора фразы *I took her flowers*


Идея. Начинаем с S и на каждом шаге заменяем один нетерминал по правилу, пока не останутся одни слова. Развилка возникает на шаге с VP : подходят оба правила, $VP \rightarrow V NP$ и $VP \rightarrow V NP NP$.

Вариант 1 — правило $VP \rightarrow V NP$, где $NP \rightarrow PRO N$:


$$\begin{aligned}
 S &\Rightarrow NP VP \Rightarrow PRO VP \Rightarrow I VP \Rightarrow I V NP \\
 &\Rightarrow I took NP \Rightarrow I took PRO N \Rightarrow I took her flowers.
 \end{aligned}$$

Вариант 2 — правило $VP \rightarrow V NP NP$, где первая $NP \rightarrow PRO$, а вторая $NP \rightarrow N$:

$$\begin{aligned}
 S &\Rightarrow NP VP \Rightarrow I VP \Rightarrow I V NP NP \Rightarrow I took NP NP \\
 &\Rightarrow I took PRO NP \Rightarrow I took her N \Rightarrow I took her flowers.
 \end{aligned}$$



Дерево 1: «Я взял её цветы»



Дерево 2: «Я отнёс ей цветы»

Ответ и смысл.


- В дереве 1 *her flowers* — одна именная группа: «её цветы» (это цветы, которые ей принадлежат). Перевод «Я взял её цветы» есть на слайде.
- В дереве 2 *her* и *flowers* — два отдельных дополнения: кому и что. Получается «я отнёс (принёс) ей цветы». Перевод второго дерева на слайде не подписан, он мой **[дополнение]**.

Цепочка слов одна, деревьев два, значит грамматика **двусмысленна**. Это и есть та развилка из лекции 1: точными правилами смысл однозначно не определить.

3. Задача 2: «Point to the second green ball»

(слайд 4)


На слайде нарисован ряд шаров, а фраза «*Point to the second green ball*» («Покажи на второй зелёный шар») подчёркнута в части *the second green ball*.




Цвета по слайду: красный, зелёный, синий, фиолетовый, зелёный, фиолетовый.

Здесь появляются новые символы: **DET** (determiner, определитель, у нас артикль *the*) и **MOD** (modifier, определение: *second, green*).

Задача 2. Какой шар имеется в виду? Разобрать *the second green ball*



Дерево А (плоское)



Дерево В (вложенное)

Дерево А. Оба определения, *second* и *green*, висят на одном уровне и независимо уточняют *ball*: «второй шар, и он зелёный». Считаем все шары подряд: второй — зелёный, подходит. **Ответ: шар № 2.**

Дерево В. Сначала *green* + *ball* собираются в группу «зелёный шар», потом *second* уточняет уже её: «второй среди зелёных шаров». Зелёные шары стоят на местах 2 и 5, второй из них — **шар № 5.**

На слайде так и нарисовано: левая стрелка (под левым деревом) указывает на шар 2, правая — на шар 5.

Вывод. Даже без многозначных слов смысл зависит от *структуры*, то есть от того, как слова сгруппированы. Человек обычно выбирает дерево В, а машине нужно это «знание» откуда-то взять: из правил или из данных.

[дополнение] правила, которые нужны для этих деревьев

На слайде правила для DET и MOD не выписаны. По самим деревьям их можно восстановить так:

$$NP \rightarrow DET N, \quad N \rightarrow MOD MOD N \mid MOD N \mid ball, \\ DET \rightarrow the, \quad MOD \rightarrow second \mid green.$$

4. Векторизация слов в NLP: базовые объекты

(слайд 5)

Отсюда начинается переход к векторам (подробно — лекция 3). Четыре понятия:

- **токен** — минимальная единица текста после токенизации (обычно слово);
- **словарь** — множество всех различных токенов: $V = \{w_1, \dots, w_K\}$, где K — размер словаря;
- **документ** — отдельный текст (предложение, отзыв, письмо), то есть последовательность токенов;
- **корпус** — набор документов: $D = \{d_1, \dots, d_N\}$, где N — число документов.

[дополнение] Пример: корпус из двух предложений «Пёс сел на пень», «Кот сел на ель» даёт $N = 2$ документа и словарь из $K = 6$ токенов. Этот пример целиком разобран в лекции 3.

5. Спорные и неоднозначные места

Место	Что в материалах	Моя гипотеза
Перевод дерева 2	На слайде подписан только перевод «я взял её цветы» под левым деревом.	Правое дерево (V NP NP) означает «отнёс/принёс ей цветы». Это стандартный пример двусмысленности.
Подпись «<Глагол, гр.>»	Рукописно и сокращённо.	«Глагольная группа» (Verb Phrase).
Правила для DET, MOD	На слайде только деревья, правил нет.	Восстановлены по деревьям (блок [дополнение] выше).
Какая стрелка к какому дереву	Стрелки на слайде 4 стоят под шарами 2 и 5, деревья нарисованы ниже под ними.	Левое (плоское) дерево → шар 2, правое (вложенное) → шар 5; это совпадает с логикой разбора.
Буква V	На слайдах V — это и «глагол» (Verb), и «словарь» $\{w_1, \dots, w_K\}$; в лекции 1 — множество нетерминалов.	Три разных смысла одной буквы. Смотри по контексту: в правилах грамматики — глагол, в векторизации — словарь.
Два слайда «Слайд 3»	Одно и то же дерево сначала нарисовано одно, потом рядом добавлено второе.	Это один слайд, который дорисовывали по ходу лекции.

6. Вопросы для самопроверки

1. Что означает вертикальная черта в правиле $NP \rightarrow N \mid PRO \mid PRO N$?
2. Выпиши вывод фразы *they took planes* в грамматике слайда 2. Сколько у неё деревьев разбора?
3. Почему у *I took her flowers* два дерева, а у *they took planes* одно?
4. Порождает ли грамматика слайда 2 фразу *they was flowers*? О чём это говорит?
5. Что означают символы DET и MOD?
6. Объясни своими словами, почему «the second green ball» может указывать на шар 2 или на шар 5.
7. Дай определения: токен, словарь, документ, корпус. Что обозначают K и N ?

Краткие ответы. 1) «Или»: NP можно заменить любым из вариантов. 2) $S \Rightarrow NP VP \Rightarrow PRO VP \Rightarrow they V NP \Rightarrow they took N \Rightarrow they took planes$. Дерево одно: правило $V NP NP$ не подходит, потому что после глагола всего одно слово. 3) В *her flowers* два слова, и их можно сгруппировать двумя способами (одна NP или две); в *planes* одно слово. 4) Да: $NP \rightarrow PRO$, $V \rightarrow was$, $NP \rightarrow N$. Грамматика не проверяет согласование и порождает неправильные фразы, то есть она слишком «щедрая». 5) DET — определитель (артикл), MOD — определение-модификатор. 6) Зависит от группировки: «второй шар, который зелёный» или «второй из зелёных». 7) См. разд. 4; K — размер словаря, N — число документов.