

АНАЛИЗ БОЛЬШИХ ДАННЫХ

Лекция 4

Методы машинного обучения для анализа текста: наивный байесовский классификатор

Предположительно 01.10.2026 (фото конспекта сделаны 04.10) · источники: 2 фотографии рукописного конспекта; слайдов нет

Как читать. Основной текст — из твоих материалов (конспект + скрины слайдов); в скобках (слайд N) указано, откуда взято. **[дополнение]** — то, чего в материалах нет, добавлено мной для понимания. **[неясность]** — место, которое нельзя восстановить однозначно; подробности в разделе «Спорные и неоднозначные места».

Ключевые определения и теоремы

Условная вероятность $p(A | B)$ — вероятность события A , если известно, что произошло B ; $0 \leq p(A | B) \leq 1$.

Формула Байеса:

$$p(A | B) = \frac{p(A)}{p(B)} \cdot p(B | A).$$

Обучение с учителем — модель учится на базе данных (БД) примеров, у которых правильный ответ (класс) известен заранее.

Вектор признаков $X = (x_1, \dots, x_n)$ описывает объект; **класс** $y = C_k$, $k = 1, \dots, M$.

Наивный байесовский классификатор выбирает класс с наибольшей вероятностью:

$$y = \arg \max_k p(C_k) \prod_{i=1}^n p(x_i | C_k)$$

(в конспекте записано без множителя $p(C_k)$, см. разд. 2.3).

«Наивное» предположение: слова (признаки) при известном классе независимы, поэтому $p(d | C_k) = \prod_i p(w_i | C_k)$.

Логарифм отношения правдоподобия для спама:

$$q = \ln \frac{p(S | d)}{p(\neg S | d)} = \ln \frac{p(S)}{p(\neg S)} + \sum_i \ln \frac{p(w_i | S)}{p(w_i | \neg S)}, \quad p(S | d) = \frac{e^q}{1 + e^q}.$$

Правило решения: если $q > h$ (порог, обычно $h = 0$), письмо — спам.

Сентимент-анализ — определение тональности текста: положительный (1) или отрицательный (0).

1. Немного теории вероятностей

(фото 1)

Лекция открывает блок «Методы машинного обучения и нейронные сети» в применении к анализу текста. Первый метод — **простой (наивный) байесовский классификатор**.

Пусть A, B, C — события. Условная вероятность $p(A | B)$ — это вероятность A при условии, что B уже произошло: $0 \leq p(A | B) \leq 1$.

Формула Байеса:

$$p(A | B) = \frac{p(A)}{p(B)} \cdot p(B | A).$$

[дополнение] откуда берётся формула и зачем она нужна

Вероятность, что произошли и A , и B , можно записать двумя способами:

$$p(A \cap B) = p(A | B) p(B) = p(B | A) p(A).$$

Делим обе части на $p(B)$ и получаем формулу Байеса.

Зачем она нужна: она позволяет «перевернуть» условие. Узнать $p(\text{слово} | \text{спам})$ легко: берём спам-письма из базы и считаем, как часто там встречается слово. А нужно нам $p(\text{спам} | \text{слово})$. Формула Байеса переводит одно в другое.

2. Обучение с учителем и байесовский классификатор

(фото 1)

2.1. Объекты и признаки

Есть **БД с примерами**: объекты, для которых уже известен правильный класс. Каждый объект описывается набором признаков. Пример из конспекта:

яблоко = (форма, цвет, размер) = (округлая форма, красный цвет, размер = 10 см).

В общем виде:

$X = (x_1, \dots, x_n)$ — вектор признаков, $y = C_k$, $k = 1, 2, \dots, M$ — класс объекта.

2.2. Обучение

По БД оцениваются вероятности $p(x_i | C_k)$: насколько часто признак x_i встречается у объектов класса C_k . Например, какая доля яблок в базе красная.

$$\text{БД} \rightsquigarrow p(x_i | C_k).$$

2.3. Классификация

Новый объект относим к классу, для которого произведение вероятностей его признаков максимально:

$$y = \arg \max_k \prod_{i=1}^n p(x_i | C_k) \quad (\text{как в конспекте}).$$

$\arg \max_k$ означает «то k , при котором выражение наибольшее». Ответом служит сам класс, а не значение выражения.

[дополнение] почему «наивный» и куда делся $p(C_k)$

- Перемножать вероятности признаков можно, только если признаки *независимы* при известном классе. В жизни это не так (цвет и сорт яблока связаны, слова в тексте тоже). Классификатор «наивно» делает вид, что независимость есть, и при этом часто работает хорошо.
- По формуле Байеса полное правило таково: $y = \arg \max_k p(C_k) \prod_i p(x_i | C_k)$. Знаменатель $p(X)$ одинаков для всех классов и на выбор не влияет. Запись из конспекта без $p(C_k)$ верна, когда все классы равновероятны. Ниже, в формулах для спама, множитель $p(S)$ в конспекте уже есть.

3. Байесовская фильтрация спама

(фото 1-2)

3.1. Постановка

Два класса: $C_1 = S$ — спам, $C_2 = \neg S$ — не спам. Корпус писем $D = \{d_i\}$, словарь $V = \{w_i\}$. $p(w_i | C_k)$ — вероятность того, что i -е слово данного документа d встречается в классе C_k . Документ — это набор слов $d = \{w_i\}$. В наивном предположении

$$p(d | C_k) = \prod_i p(w_i | C_k).$$

Вопрос: какова вероятность того, что данный документ d принадлежит классу C_k , то есть чему равно $p(C_k | d)$? По формуле Байеса:

$$p(C_k | d) = \frac{p(C_k)}{p(d)} \cdot p(d | C_k).$$

Для двух наших классов:

$$p(S | d) = \frac{p(S)}{p(d)} \prod_i p(w_i | S), \quad p(\neg S | d) = \frac{p(\neg S)}{p(d)} \prod_i p(w_i | \neg S).$$

3.2. Отношение правдоподобия и его логарифм

Неизвестную $p(d)$ посчитать трудно, но она *сокращается*, если поделить одно на другое. Получается **отношение правдоподобия**:

$$\frac{p(S | d)}{p(\neg S | d)} = \frac{p(S)}{p(\neg S)} \cdot \prod_i \frac{p(w_i | S)}{p(w_i | \neg S)}.$$

Берём натуральный логарифм. Произведение превращается в сумму, и получается **логарифм правдоподобия**:

$$q = \ln \frac{p(S | d)}{p(\neg S | d)} = \ln \frac{p(S)}{p(\neg S)} + \sum_i \ln \frac{p(w_i | S)}{p(w_i | \neg S)}.$$

[дополнение] Логарифм нужен на практике: произведение сотен маленьких вероятностей становится настолько близким к нулю, что компьютер округляет его до 0. Сумма логарифмов такой проблемы не имеет. Кроме того, каждое слово даёт свой понятный «вклад»: плюс — за спам, минус — против.

3.3. Как из q получить вероятность


В конспекте: $p(S | d) + p(\neg S | d) = 1$ и $p(S | d) = \frac{e^q}{1 + e^q}$, $0 \leq p \leq 1$. Вывод **[дополнение]**:

Задача 1. Вывести $p(S | d)$ через q

Обозначим $p = p(S | d)$. Тогда $p(\neg S | d) = 1 - p$, и по определению q :

$$\ln \frac{p}{1-p} = q \implies \frac{p}{1-p} = e^q \implies p = e^q - p e^q \implies p(1 + e^q) = e^q \implies p = \frac{e^q}{1 + e^q}.$$

Проверка: при любом q числитель меньше знаменателя и оба положительны, поэтому $0 < p < 1$, как и должно быть у вероятности.



[дополнение] График $p = \frac{e^q}{1 + e^q}$ (сигмоида, или логистическая функция).

3.4. Правило решения

Задаётся **порог** h ; в конспекте $h = 0$. Если $q > h$, письмо считается **спамом**.

Почему $h = 0$ естественно: $q > 0$ означает $\frac{p(S|d)}{p(\neg S|d)} > 1$, то есть спам вероятнее, чем не спам, и $p(S | d) > \frac{1}{2}$. Если увеличить h , фильтр будет «осторожнее» и реже станет помечать нормальные письма как спам.

Задача 2 ([дополнение]). Спам или нет?

Пусть по базе писем получено: $p(S) = 0,4$, $p(\neg S) = 0,6$, и для трёх слов

слово w	$p(w S)$	$p(w \neg S)$	$\ln \frac{p(w S)}{p(w \neg S)}$
«выигрыш»	0,05	0,005	$\ln 10 \approx +2,303$
«бесплатно»	0,04	0,01	$\ln 4 \approx +1,386$
«отчёт»	0,01	0,02	$\ln 0,5 \approx -0,693$

Письмо $d = \{\text{выигрыш, бесплатно, отчёт}\}$. Спам ли это при $h = 0$?

Решение.

$$q = \underbrace{\ln \frac{0,4}{0,6}}_{\approx -0,405} + 2,303 + 1,386 - 0,693 \approx 2,590 > 0 \Rightarrow \text{спам.}$$

$$p(S | d) = \frac{e^{2,590}}{1 + e^{2,590}} \approx \frac{13,33}{14,33} \approx 0,93.$$

Слова «выигрыш» и «бесплатно» тянут в сторону спама, «отчёт» — в обратную, но его вклад меньше.

Откуда берутся числа $p(w | S)$: это доля слова w среди всех слов спам-писем базы. Если слово ни разу не встретилось в спаме, получится $p = 0$ и $\ln 0$ не определён. Поэтому на практике ко всем счётчикам прибавляют 1 (сглаживание Лапласа).

4. Сентимент-анализ отзывов на фильмы

(фото 2)

Задача: по тексту рецензии определить её тональность — положительная (**1**) или отрицательная (**0**).

- БД: **50 000** рецензий.
- Тест: **7500** положительных и **7500** отрицательных отзывов.

Результаты трёх подходов (вектор текста + классификатор):

№	Векторизация	Классификатор	Результат (по конспекту)
1	мешок слов (BoW)	наивный Байес (NB)	84,6 %
2	TF-IDF	наивный Байес (NB)	85,3 %
3	TF-IDF	нейросеть (в конспекте «NW»)	88,0 %

Для варианта 1 в конспекте записаны ещё четыре числа:

6696 804
6515 985

Задача 3. Как читать числа 6696, 804, 6515, 985

Заметим: $6696 + 804 = 7500$ и $6515 + 985 = 7500$. Значит, каждая строка — один класс тестовой выборки (7500 отзывов), разбитый на «угадано / ошибка». Скорее всего:

	классифицировано верно	ошибка	всего
положительные (1)	6696	804	7500
отрицательные (0)	6515	985	7500

Тогда **доля верных ответов** (ассурасу) **[дополнение]**:

$$\text{Accuracy} = \frac{6696 + 6515}{15\,000} = \frac{13\,211}{15\,000} \approx 0,881 = 88,1\%.$$

Это не совпадает с записанными 84,6 % **[неясность]**. Я перебрал другие естественные прочтения — ни одно не даёт 84,6 %. Что-то из этого записано с ошибкой: либо проценты, либо одно из чисел (подробнее — в разделе 5). Уточни у преподавателя или в чужом конспекте.

Главный вывод лекции от этого не зависит: TF-IDF работает лучше простого мешка слов (редкие информативные слова получают больший вес), а нейросеть на тех же TF-IDF-векторах даёт лучший результат из трёх.

[дополнение] Набор из 50 000 рецензий очень похож на известный открытый датасет IMDb (Large Movie Review Dataset), но в конспекте это не сказано.

5. Спорные и неоднозначные места

Место	Что в материалах	Моя гипотеза
Точность варианта 1	6696/804, 6515/985 и «84,6 %».	По числам выходит 88,1 % (и это почти совпадает с 88,0 % у нейросети). Возможно, числа записаны от другого эксперимента или ошибка в процентах. [неясность]
«NW»	В варианте 3: «TF-IDF NW».	Нейросеть (NN, neural network / «НС»).
$X = (x_1, \dots, x_2)$	Последний индекс читается как «2» (или «z»).	Должно быть x_n : признаков произвольное число n , по нему идёт произведение.
$\arg \max$ без $p(C_k)$	$y = \arg \max_k \prod p(x_i C_k)$.	Неполная запись; полная — с $p(C_k)$ (верна при равновероятных классах). В формулах для спама $p(S)$ уже есть.
Индекс i у w_i	$V = \{w_i\}$ — слова словаря, но $p(w_i C_k)$ — « i -е слово данного документа».	Одна буква используется в двух смыслах. В формуле $\prod_i$ имеется в виду перебор слов документа.
Размер обучающей выборки	Дано «50 000 рецензий» и тест 7500 + 7500.	Обучение, вероятно, на оставшихся 50 000 – 15 000 = 35 000; в конспекте это не указано.
Дата лекции	Фото сделаны 04.10.	Сама лекция, вероятно, в четверг 01.10 (предыдущие были 10.09, 17.09, 24.09).
«БД»	Сокращение.	База данных (размеченные примеры).

6. Вопросы для самопроверки

1. Запиши формулу Байеса и объясни, что в ней «переворачивается».
2. Что такое обучение с учителем? Что хранится в «БД с примерами»?
3. Почему классификатор называется «наивным»?
4. Что означает $\arg \max_k$? Почему знаменатель $p(d)$ можно не считать?

5. Зачем переходить от отношения правдоподобия к его логарифму?
6. Выведи $p(S | d) = \frac{e^q}{1 + e^q}$ из $p(S | d) + p(\neg S | d) = 1$.
7. Чему равна $p(S | d)$ при $q = 0$? При $q \rightarrow +\infty$?
8. В задаче 2 замени $p(S) = 0,4$ на $p(S) = 0,1$. Останется ли письмо спамом?
9. Почему TF-IDF дал лучший результат, чем мешок слов, на одном и том же классификаторе?

Краткие ответы. 1) $p(A | B) = \frac{p(A)}{p(B)}p(B | A)$: от легко считаемой $p(\text{слово} | \text{класс})$ переходим к нужной $p(\text{класс} | \text{слово})$. 2) Модель учится на примерах с известными ответами (классами). 3) Признаки считаются независимыми при известном классе. 4) Номер класса с наибольшим значением; $p(d)$ одинаково для всех классов, а в отношении правдоподобия сокращается. 5) Произведение превращается в сумму, нет исчезающе малых чисел. 6) См. задачу 1. 7) $\frac{1}{2}; \rightarrow 1$. 8) $\ln \frac{0,1}{0,9} \approx -2,197$, $q \approx -2,197 + 2,996 = 0,799 > 0$ — всё ещё спам, $p \approx 0,69$. 9) TF-IDF снижает вес частых неинформативных слов и усиливает характерные слова.